

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет Программной инженерии и компьютерной техники

Образовательная программа Проектирование и разработка систем искусственного интеллекта 2025

Направление подготовки (специальность) 09.04.04 - Программная инженерия

О Т Ч Е Т

о Научно-исследовательской работе

Тема задания: Обзор предметной области тематики выпускной квалификационной работы

Обучающийся: *Ботыгин Глеб Вадимович, № Р4144*

Руководитель практики от университета: *Маркина Татьяна Анатольевна, старший преподаватель факультета программной инженерии и компьютерной техники*

Дата 05.01.2026

Санкт-Петербург
2026

Введение

Тема практики: Обзор предметной области тематики выпускной квалификационной работы

Цель НИР: Провести анализ существующих методов выявления дрейфа данных, таких как статистические тесты, и механизмов обнаружения падения качества модели на основе обратной связи от интегрированных внешних систем (например, через метрики точности, конверсии или ручную оценку результатов) для повышения надежности и устойчивости ML моделей, внедряемых в production в рамках MLOps системы (например, рекомендательных моделей для телеком-операторов или классификаторов обращений в тех. поддержку). Оценить каждый подход по следующим критериям: чувствительность к дрейфу и деградации качества, частота ложных срабатываний, вычислительная стоимость, задержка обнаружения, интегрируемость в MLOps систему и требования к разметке. Анализ должен быть выполнен с использованием открытых инструментов (Evidently AI, MLflow) и экспериментальной проверки на реальных или синтетических наборах данных общим объемом не менее 20 000 записей, с имитацией обратной связи в виде агрегированных метрик качества. Результаты анализа позволят спроектировать и прототипировать унифицированный механизм, объединяющий мониторинг дрейфа признаков и деградации предсказаний через обратную связь, что приведет к снижению количества непредвиденных падений точности модели на 20%. Проект должен быть завершен к 25 января 2026 года.

Таблица 1 – Рабочий план-график практики из модуля практики my.itmo

№ этапа	Название этапа	Период:	Задание
1	2	3	4
1	Инструктаж обучающегося	03.11.2025	Инструктаж обучающегося по ознакомлению с требованиями охраны труда, техники безопасности, пожарной безопасности, а также правилами внутреннего трудового распорядка.

2	Заполнение и утверждение задания	с 03.11.2025 по 09.11.2025	Заполнить в разделе Практика задание на НИР и отправить на согласование руководителю практики.
3	Составить список источников для аналитического обзора	с 03.11.2025 по 30.11.2025	Источники должны быть не старше 5 лет. Допускаются источники старше 5 лет, но они должны быть в меньшем количестве. В качестве источников могут быть статьи, тезисы, книги, учебные пособия и др. Минимальное количество источников: 10. Должен быть оформлен в соответствии с ГОСТ 7.32-2017.
4	Написать аналитический обзор по тематике ВКР	с 01.12.2025 по 11.01.2026	Провести анализ существующих методов выявления дрейфа данных, таких как статистические тесты, и механизмов обнаружения падения качества модели на основе обратной связи от интегрированных внешних систем (например, через метрики точности, конверсии или ручную оценку результатов) для повышения надежности и устойчивости ML моделей, внедряемых в production в рамках MLOps системы (например, рекомендательных моделей для телеком-операторов или классификаторов обращений в тех. поддержку). Оценить каждый подход по следующим критериям: чувствительность к дрейфу и деградации качества, частота ложных срабатываний, вычислительная стоимость, задержка обнаружения, интегрируемость в MLOps систему и

			требования к разметке. Анализ должен быть выполнен с использованием открытых инструментов (Evidently AI, MLflow) и экспериментальной проверки на реальных или синтетических наборах данных общим объемом не менее 20 000 записей, с имитацией обратной связи в виде агрегированных метрик качества. Результаты анализа позволяют спроектировать и прототипировать унифицированный механизм, объединяющий мониторинг дрейфа признаков и деградации предсказаний через обратную связь, что приведет к снижению количества непредвиденных падений точности модели на 20%. Проект должен быть завершен к 25 января 2026 года. Требования к аналитическому обзору Обзор 10–15 ключевых источников (патенты, статьи, промышленные стандарты и др) по применяемым технологиям/методам. Сравнительный анализ аналогов/вариантов решения задач (таблица с критериями: точность, скорость, стоимость, ограничения и другими, определенными с руководителем ВКР). Описание актуальности, включающая в себя обоснование выбора темы ВКР (почему эта проблема важна) или почему не стоит этим заниматься. Выводы по применимости к конкретной практической задаче (какие методы
--	--	--	---

			подходят для решения поставленной задачи, а какие имеют недостатки). Структура аналитического обзора: Введение в проблему (1-2 стр.) включает описание практической задачи, объяснение, почему существующие решения не идеальны и не подходят под ограничения задачи или предметной области, а также формулировку цели анализа. Сравнительный анализ методов (4-8 стр.) содержит графическую сводку (например, диаграмму "Точность vs Быстродействие"), текстовые комментарии к таблице и графике, а также другие текстовые комментарии, отражающие сравнение. Описание актуальности (1-2 стр.) обосновывает выбор темы ВКР — почему эта проблема важна, или почему не стоит этим заниматься. Выводы для практического применения (1-2 стр.) указывают, какой метод выбран для реализации и почему, а также какие модификации потребуются. Список использованных источников завершает обзор.
--	--	--	---

5	Оформление отчёта, получение отзыва с оценкой от руководителя	с 17.11.2025 по 25.01.2026	Написание отчёта, оформление в соответствии с требованиями, получение отзыва от руководителей. Оформление отчётных документов в соответствии с требованиями: 1.Оформление отчёта должно быть выполнено в соответствии с методическим пособием (https://books.ifmo.ru/file/pdf/2622.pdf , разделы "Набор текста ", "Нумерация страниц и разделов ", "Заголовки разделов ", "Оформление рисунков ", "Оформление таблиц ", "Оформление формул ", "Оформление ссылок на источники ", "Оформление списка использованных источников ", "Оформление приложений"). 2.Структура документа: титульный лист, введение, основная часть, заключение, приложения. 3.В основной части подробно описывается выполнение задач всех этапов. Получить отзыв с оценкой у руководителя практики в модуле Практика.
---	--	----------------------------	--

Заполнение и утверждение задания

В рамках начального этапа практики было выполнено формирование и загрузка задания в электронном модуле «Практика» информационной системы *my.itmo*. Основой для подготовки задания послужили утверждённый шаблон, предоставленный руководителем практики, а также методические материалы, определяющие допустимые форматы исследований и требования к их содержанию.

Подготовка задания началась с анализа структуры формы, в которой предусматривалось поэтапное описание хода практики с указанием сроков и содержания выполняемых работ. В соответствии с данной структурой данные из шаблона были адаптированы и внесены в соответствующие поля электронной формы. При этом особое внимание уделялось согласованию сроков выполнения этапов с календарным графиком практики и логической последовательности выполняемых работ.

Существенным шагом на данном этапе являлось определение типа исследования, поскольку от этого зависело содержание и формат заполнения задания. Для принятия решения были изучены пояснительные материалы, содержащие описание особенностей практико-ориентированных и научно-аналитических исследований. С учётом того, что выполняемая работа направлена на решение прикладной задачи, связанной с анализом и практическим применением методов мониторинга дрейфа данных и качества ML-моделей, был выбран формат практико-ориентированного исследования.

После выбора типа исследования было выполнено детальное заполнение всех этапов задания. Основной акцент был сделан на этапе, связанном с подготовкой аналитического обзора по тематике выпускной квалификационной работы. В описание данного этапа были включены цель исследования, сформулированная в соответствии с принципами SMART, а также требования к содержанию и структуре аналитического обзора. Формирование этих элементов осуществлялось на основе методических рекомендаций и с учётом предполагаемого практического результата работы.

По завершении заполнения электронная форма задания была направлена на согласование руководителю практики через функционал модуля «Практика». В процессе согласования было выявлено несоответствие указанной темы шаблону, а также отклонение цели от шаблона формулировки по SMART. После исправление выявленных недостатков, исправленная версия была повторно направлена на согласование с руководителем и утверждена без замечаний. Утверждённая версия задания была зафиксирована в системе и включена в отчёт по практике в виде Приложения 1, отражающего результат выполнения данного этапа.

Составление список источников для аналитического обзора

Перед началом непосредственного поиска научных и прикладных источников была проведена предварительная подготовка, направленная на формирование корректной стратегии информационного поиска. В качестве методологической основы был использован гайд по поиску информации в сети, предоставленный преподавателем (документ «Ищем и находим. Большой гайд» от Experimental Media). Данный материал был полностью изучен до начала работы с источниками, что позволило структурировать процесс поиска, осознанно подойти к формированию поисковых запросов и избежать некритичного отбора материалов из поисковой выдачи.

На основе рекомендаций из гайда была выбрана стратегия долгосрочного поиска, ориентированного на сбор репрезентативного корпуса источников по теме обнаружения и управления дрейфом данных в производственных ML-системах. В рамках данной стратегии были определены ключевые тематические кластеры: теоретические основы концептуального дрейфа, практические методы его обнаружения, такие как статистические тесты, методы обнаружения падения качества моделей на основе метрик, специфика дрейфа в текстовых и рекомендательных системах, а также современные инструменты и платформы для MLOps и мониторинга моделей. Поиск источников осуществлялся с использованием поисковой системы Google Scholar. Для первичного сравнения open-source инструментов по выявлению дрейфа данных был использован сервис

chat.qwen.ai с режимом веб-поиска и следующим промптом «Проанализируй несколько основных open-source инструментов используемых для выявления дрейфа данных в машинном обучении (таких как evidently AI). Составь сравнение по следующим критериям: количество поддерживаемых методов обнаружения дрейфа, удобство интеграции с MLOps пайплайнами, скорость работы, наличие встроенных визуализаций и отчетов». Для каждого направления формировались отдельные поисковые запросы с вариациями формулировок, такими как: “concept drift review”, “data drift detection in text classification”, “automated retraining pipeline”, “real and virtual concept drift”, “MLOps production pipelines”, “open-source drift detection tools”, “recommendation systems concept drift”, “model performance degradation delayed labels”.

На первичном этапе отбора проводился анализ аннотаций и введения статей, а также использовался chat.qwen.ai для получения краткого пересказа текстов статей. Окончательное решение о включении источника в список принималось только после самостоятельного анализа его содержания и оценки соответствия следующим критериям: тематическая релевантность, наличие экспериментальной или практической составляющей, новизна подхода и соответствие временному диапазону (приоритет отдавался работам не старше 10 лет, за исключением фундаментальных обзоров).

В результате был сформирован итоговый список источников, включающий как фундаментальные обзоры, так и современные прикладные исследования и инструменты. Краткое обоснование выбора каждого источника приведено ниже:

1. Alibi Detect — выбран как один из ведущих open-source инструментов для обнаружения дрейфа, поддерживающий широкий спектр методов и различные типы данных (текст, изображения, табличные данные).
2. Deshpande et al. (2025) — выбран как комплексное описание готового end-to-end pipeline для автоматического обнаружения дрейфа и переобучения, что демонстрирует практическую реализацию MLOps-подхода.

3. Benni et al. (2024) — выбран для понимания различий в поведении моделей при реальном и виртуальном дрейфе, а также для оценки эффективности гибридных ансамблевых стратегий адаптации.
4. Evidently AI — выбран как популярная и функционально богатая библиотека для профилирования данных и обнаружения дрейфа, часто используемая в промышленных решениях.
5. Feldhans et al. (2021) — выбран для анализа применимости методов обнаружения дрейфа к высокоразмерным текстовым эмбедингам.
6. Gama et al. (2004) — выбран как одна из ранних и фундаментальных работ, заложивших основы для многих современных методов обнаружения дрейфа.
7. Garcia & Koerich (2024) — выбран для изучения методов генерации контролируемого дрейфа в текстовых потоках, что важно для валидации и тестирования собственных модулей детекции.
8. Chidiebere (2025) — выбран как пример практического применения статистических методов (через Evidently AI) в автоматизированном pipeline, дополняющий работу Deshpande et al.
9. Lu et al. (2020) — выбран как авторитетный и всеобъемлющий обзор области, который предоставляет единую концептуальную рамку (обнаружение, понимание, адаптация) и классификацию методов.
10. MLflow — выбран как стандарт де-факто для управления жизненным циклом ML-моделей, что позволяет интегрировать модуль обнаружения дрейфа в существующие MLOps-практики.
11. River — выбран как специализированная библиотека для онлайн-обучения и обработки потоковых данных, предоставляющая готовые реализации алгоритмов обнаружения дрейфа (ADWIN, DDM и др.).
12. Müller et al. (2024) — выбран для проведения сравнительного анализа трёх ключевых open-source инструментов (Evidently, NannyML, Alibi-Detect) на реальных данных, что даёт практические рекомендации по их применению.

13. NannyML — выбран за его уникальную способность оценивать производительность модели без ground truth и точно определять время возникновения дрейфа.
14. Wanas et al. (2019) — выбран для изучения специфики дрейфа в рекомендательных системах и подхода IKCD, который использует кластеризацию для unsupervised-детекции и сохраняет исторические данные при переобучении.
15. WhyLabs / whylogs — выбран как инструмент для легковесного логирования статистик данных, что является важным компонентом для построения масштабируемых систем мониторинга.
16. Xin et al. (2021) — выбран для получения эмпирических данных о реальных производственных ML-пайплайнах, включая частоту переобучений, распределение вычислительных затрат и проблему «потраченных вычислений».

В ходе систематического поиска и отбора источников было рассмотрено значительное количество публикаций, часть из которых не вошла в итоговый список. Ниже приведены примеры таких исключённых работ.

«Failing loudly: An empirical study of methods for detecting dataset shift» (Rabanser et al., 2019). Несмотря на релевантную тематику - сравнение статистических методов обнаружения сдвига распределений - исследование фокусируется преимущественно на оценке качества детекторов в условиях, когда ground truth доступен, и не рассматривает интеграцию в production-пайплайны или стратегии реагирования на дрейф. Данная статья не вносит новых подходов относительно других рассмотренных работ с комплексным анализом.

Другим примером является работа «Unsupervised concept drift detection from deep learning representations in real-time» (Soe et al., 2023). Хотя подход, основанный на эмбедингах, выглядит перспективным, в статье не приводится сравнение с другими методами. Кроме того, авторы не предоставляют открытого

кода, что затрудняет воспроизводимость и практическое применение предложенного решения.

Также был рассмотрен, но исключён обзор «From concept drift to model degradation: An overview on performance-aware drift detectors» (Bayram et al., 2022). Несмотря на полноту охвата теоретических аспектов, работа носит преимущественно обобщающий характер и не предлагает новых методологических или архитектурных решений. Она не содержит практических кейсов внедрения, сравнения open-source инструментов или рекомендаций по проектированию end-to-end pipeline, что делает её менее полезной для задачи разработки прикладного модуля обнаружения дрейфа.

Все исключённые источники либо не вносят новизну относительно других рассмотренных источников, либо носят сугубо теоретический характер и недостаточно ориентированы на практическое применение, либо не соответствуют ключевым критериям отбора: тематической релевантности, наличию экспериментальной оценки, применимости в production-средах и поддержке современных сценариев.

Использование формализованных критериев отбора позволило обоснованно сформировать итоговый список источников, включающий научные статьи, препринты и прикладные инструменты, непосредственно используемые при написании аналитического обзора. Данный список оформлен в соответствии с требованиями ГОСТ 7.32–2017.

Написание аналитического обзора по тематике ВКР

Основная часть практики была посвящена выполнению аналитического обзора и экспериментального исследования в области мониторинга дрейфа данных и деградации качества моделей машинного обучения, функционирующих в production-средах. Данный этап практики был ориентирован на анализ существующих методов выявления изменений во входных данных и поведении моделей, а также на оценку их применимости в рамках MLOps-процессов,

предполагающих автоматизированное принятие решений о повторном обучении моделей.

Перед началом непосредственной работы над обзором были уточнены цель исследования и формальные требования к его содержанию и структуре, зафиксированные в задании на практику. С учётом прикладного характера рассматриваемой задачи был выбран практико-ориентированный формат аналитического обзора, предполагающий акцент на сравнении подходов с точки зрения их эксплуатационных характеристик, устойчивости к различным типам дрейфа и рисков ложных срабатываний в production-сценариях. Структура обзора формировалась в соответствии с методическими рекомендациями и включала обоснование актуальности темы, анализ и классификацию видов дрейфа, обзор методов мониторинга данных и качества моделей, а также формулировку выводов, ориентированных на практическое применение.

В ходе написания раздела, посвящённого классификации видов дрейфа, особое внимание было уделено различиям между covariate drift, concept drift и virtual drift, а также сложности их выявления в реальных production-системах. Анализ показал, что статистические сдвиги распределений признаков не всегда сопровождаются деградацией качества моделей, что принципиально ограничивает применение исключительно data-centric подходов. Эти выводы стали основой для последующего перехода к анализу методов мониторинга, ориентированных на поведение модели.

При рассмотрении подходов к мониторингу было проведено сравнение двух основных стратегий: запуска переобучения по факту падения метрик качества и использования алгоритмов обнаружения точек изменения, таких как ADWIN. В рамках обзора подробно анализировались их преимущества и ограничения, включая задержку обнаружения деградации, чувствительность к шуму, требования к разметке и риск избыточных переобучений. Отдельное внимание уделялось практическому контексту MLOps, в котором такие алгоритмы используются не только как аналитические инструменты, но и как элементы автоматизированных pipeline'ов.

Параллельно с аналитическим обзором была выполнена экспериментальная часть работы, направленная на практическую оценку влияния дрейфа данных на качество моделей классификации. Для этого с помощью `scikit-learn` были сгенерированы синтетические наборы данных с контролируемыми сценариями дрейфа, включая комбинации изменений распределений признаков и изменений зависимости между признаками и целевой переменной. На полученных данных были проведены статистические тесты с использованием `Evidently AI`. На исходных данных обучались модели логистической регрессии и случайного леса, после чего их качество оценивалось на исходных и смещённых выборках с использованием одинаковых индексов. В качестве метрик использовались `accuracy` и `F1-score`.

Результаты экспериментов были сопоставлены с выводами аналитического обзора. Было показано, что статистические тесты стабильно выявляют изменения распределений признаков, однако сложные модели, такие как случайный лес, в ряде сценариев практически не демонстрируют деградации качества. Это подтверждает риск ложных срабатываний при использовании статистических методов в качестве единственного триггера для переобучения и подчёркивает необходимость комбинированного мониторинга.

В процессе работы проводилась регулярная проверка текста на логическую связность и соответствие сформулированной цели исследования. Особое внимание уделялось тому, чтобы выводы основывались на проведённом анализе и экспериментальных результатах, а не представляли собой пересказ источников. Подготовленная версия аналитического обзора была направлена руководителю практики для получения обратной связи. Итоговая версия аналитического обзора и описание экспериментальных результатов были оформлены в соответствии с требованиями и включены в отчёт по практике в качестве основного результата данного этапа.

Заключение

В ходе прохождения научно-исследовательской практики была достигнута поставленная цель, заключающаяся в проведении аналитического обзора и экспериментальной оценки методов выявления дрейфа данных и деградации качества моделей машинного обучения в production-средах с учётом требований MLOps и автоматизированных контуров переобучения.

В рамках практики последовательно были решены все поставленные задачи. На начальном этапе было сформировано и согласовано задание на практику с выбором практико-ориентированного типа исследования и определением структуры аналитического обзора. Далее был проведён отбор и анализ актуальных научных и прикладных источников, включающих исследования в области data drift, concept drift, мониторинга качества моделей и построения устойчивых production-ML-систем.

Ключевым результатом практики стало выполнение аналитического обзора, в котором были систематизированы и сравнены основные подходы к мониторингу устойчивости ML-моделей: статистические методы анализа распределений признаков, подходы, основанные на контроле падения метрик качества, а также алгоритмы обнаружения точек изменения, в частности ADWIN. В ходе анализа были выявлены ограничения использования статистических тестов в качестве единственного триггера переобучения, показана их высокая чувствительность к covariate drift и склонность к ложным срабатываниям при отсутствии реальной деградации качества моделей. Отдельно была обоснована практическая ценность методов, ориентированных на динамику ошибок и метрик, для обнаружения сложных форм concept drift.

Экспериментальная часть работы дополнила теоретические выводы и позволила на практике оценить влияние различных сценариев дрейфа на качество моделей классификации. Проведённые эксперименты с синтетически сгенерированными смещёнными данными показали, что деградация метрик accuracy и F1-score не всегда коррелирует с обнаруживаемыми статистическими изменениями распределений признаков, особенно при использовании устойчивых

и нелинейных алгоритмов. Полученные результаты подтвердили необходимость комбинированного подхода к мониторингу, объединяющего анализ данных и контроль поведения модели.

Проведённая работа позволила не только обобщить существующие научные и инженерные подходы, но и критически оценить их применимость к реальным production-сценариям, характерным для корпоративных ML-систем. Результаты аналитического обзора и экспериментов могут быть использованы при проектировании MLOps-систем мониторинга и автоматизированного переобучения моделей, а также служат теоретической и методологической основой для дальнейшей работы над выпускной квалификационной работой.

Таким образом, цели и задачи научно-исследовательской практики были выполнены в полном объёме, а полученные результаты соответствуют требованиям к практико-ориентированному исследованию и имеют практическую ценность для дальнейшей научной и прикладной деятельности в области эксплуатации ML-моделей в production-средах.

ПРИЛОЖЕНИЕ А Фиксация заполненного задания

Практики / Научно-исследовательская работа

Карточка практикиИндивидуальное заданиеОтчет о практикеОтзыв руководителя

Индивидуальное задание Утверждено

Тема: Обзор предметной области тематики выпускной квалификационной работы

Рабочий план-график

№ этапа	Название этапа	Период	Задание
1	Инструктаж обучающегося	1	Инструктаж обучающегося по совмещению с требованиями охраны труда, техники безопасности, пожарной безопасности, а также правилами внутреннего трудового распорядка
2	Заполнение и утверждение задания	7	
3	Составить список источников для аналитического обзора	28	Источники должны быть не старше 5 лет. Допускаются источники старше 5 лет, но они должны быть в меньшем количестве. В качестве источников могут быть статьи, тезисы, книги, учебные пособия и др. Минимальное количество источников: 10. Должен быть оформлен в соответствии с ГОСТ 7.32-2017.
4	Написать аналитический обзор по тематике ВКР	42	Провести анализ существующих методов выявления дрейфа данных, таких как статистические тесты, и механизмов обнаружения падения качества модели на основе обратной связи от интегрированных внешних систем (например, через метрики точности, конверсии или ручную оценку результатов) для повышения надежности и устойчивости ML-модели, внедряемых в production в рамках MLOps системы (например, рекомендательных моделей для телеком-операторов или классификаторов обращений в тех. поддержку). Оценить каждый подход по следующим критериям: чувствительность к дрейфу и деградации качества, частота ложных срабатываний, вычислительная стоимость, задержка обнаружения, интегрируемость в MLOps систему и требования к разметке. Анализ должен быть выполнен с использованием открытых инструментов (Jupyter AI, MLflow) и экспериментальной проверки на реальных или синтетических наборах данных общим объемом не менее 20 000 записей, с имитацией обратной связи в виде агрегированных метрик качества. Результаты анализа позволяют спроектировать и прототипировать унифицированный механизм, объединяющий мониторинг дрейфа признаков и деградации предсказаний через обратную связь, что приведет к снижению количества неадекватных падений точности модели на 20%. Проект должен быть завершен к 25 января 2026 года. Требования к аналитическому обзору: Обзор 10-15 ключевых источников (патенты, статьи, промышленные стандарты и др.) по применяемым технологиям/методам. Сравнительный анализ аналогов/вариантов решения задач (таблица с критериями: точность, скорость, стоимость, ограничения и другими, определенными с руководителем ВКР). Описание актуальности, включающее в себя обоснование выбора темы ВКР (почему эта проблема важна) или почему не стоит этим заниматься. Выводы по применимости к конкретной практической задаче (какие методы подходят для решения поставленной задачи, а какие имеют недостатки). Структура аналитического обзора: Введение в проблему (1-2 стр.) включает описание практической задачи, объяснение, почему существующие решения не идеальны и не подходят под ограничения задачи или предметной области, а также формулировку цели анализа. Сравнительный анализ методов (4-8 стр.) содержит графическую сводку (например, диаграмму "Точность vs Быстродействие"), текстовые комментарии к таблице и графике, а также другие текстовые комментарии, отражающие сравнение. Описание актуальности (1-2 стр.) обосновывает выбор темы ВКР — почему эта проблема важна, или почему не стоит этим заниматься. Выводы для практического применения (1-2 стр.) указывают, какой метод выбран для реализации и почему, а также какие модификации потребуются. Список использованных источников завершает обзор.
5	Оформление отчёта, получение отзыва с оценкой от руководителя	70	Написание отчёта, оформление в соответствии с требованиями, получение отзыва от руководителей. Оформление отчётных документов в соответствии с требованиями: 1. Оформление отчёта должно быть выполнено в соответствии с методическим пособием (https://books.itmo.ru/file/pdf/2622.pdf , разделы "Набор текста", "Нумерация страниц и разделов", "Заголовки разделов", "Оформление рисунков", "Оформление таблиц", "Оформление формул", "Оформление ссылок на источники", "Оформление списка использованных источников", "Оформление приложений"). 2. Структура документа: титульный лист, введение, основная часть, заключение, приложения. 3. В основной части подробно описывается выполнение задач всех этапов. Получить отзыв с оценкой у руководителя практики в модуле Практика.

Рисунок А.1 – Рабочий план-график практики из модуля практики my.itmo

ПРИЛОЖЕНИЕ Б Список использованных источников

1. Alibi Detect: Algorithms for outlier, adversarial and drift detection — URL: <https://github.com/SeldonIO/alibi-detect> (дата обращения: 23.11.2025).
2. Abhay, Dr., K K Vamsheesh, Mattihalli P., Namith G., Kumar R. S. Automated Drift Detection and Retraining Pipeline for ML Models // International Journal of Scientific Research in Engineering and Management (IJSREM). — 2025. — URL: <https://ijsrem.com/download/automated-drift-detection-and-retraining-pipeline-for-ml-models> (дата обращения: 22.11.2025).
3. Benni, Rashmi & Totad, Shashikumar & Mulimani, Deepa & K G, Karibasappa. Impact analysis of real and virtual concept drifts on the predictive performance of classifiers // Procedia Computer Science. — 2024. — Vol. 235. P. 617–627.
4. Evidently AI. — URL: <https://github.com/evidentlyai/evidently> (дата обращения: 23.11.2025).
5. Feldhans R., Wilke A., Heindorf S., Shaker M. H., Hammer B., Ngonga Ngomo A.-C., Hüllermeier E. Drift Detection in Text Data with Document Embeddings // Intelligent Data Engineering and Automated Learning, — 2021. — URL: https://www.researchgate.net/publication/356476524_Drift_Detection_in_Text_Data_with_Document_Embeddings (дата обращения: 28.11.2025).
6. Gama J., Medas P., Castillo G., Rodrigues P. Learning with drift detection // Brazilian Symposium on Artificial Intelligence. — 2004. — P. 286–295.
7. Garcia C. M., Koerich A. L., Britto Jr. A. de S., Barddal J. P. Methods for Generating Drift in Text Streams // arXiv preprint arXiv:2403.12328. — 2024. — URL: <https://arxiv.org/abs/2403.12328> (дата обращения: 28.11.2025).
8. Joshua Chidiebere. Automating Model Drift Detection in Production ML Pipelines Using Anomaly Detection Techniques // IEEE Transactions on Microwave Theory and Techniques, — 2025. — URL: https://www.researchgate.net/publication/392592315_Automating_Model_Drift_Detection_in_Production_ML_Pipelines_Using_Anomaly_Detection_Techniques (дата обращения: 23.11.2025).
9. Lu J., Liu A., Dong F., Gu F., Gama J., Zhang G. Learning under Concept Drift: A Review // IEEE Transactions on Knowledge and Data Engineering. — 2020. — Vol. 31, No. 12. P. 2346–2363.

10. MLflow: An open-source platform for the machine learning lifecycle. — URL: <https://github.com/mlflow/mlflow> (дата обращения: 28.11.2025).
11. River: machine learning for streaming data in Python // GitHub, — 2021-2025. — URL: <https://github.com/online-ml/river> (дата обращения: 27.11.2025).
12. Müller R., Abdelaal M., Stjelja D. Open-Source Drift Detection Tools in Action: Insights from Two Use Cases // arXiv preprint arXiv:2404.18673. — 2024. — URL: <https://arxiv.org/abs/2404.18673> (дата обращения: 23.11.2025).
13. NannyML: Open-source Python library for model monitoring in production. — 2020–2025. — URL: <https://github.com/NannyML/nannyml> (дата обращения: 23.11.2025).
14. Nayer W., Farouk A., Said D., Khodeir N., Fayek M. Detection and Handling of Different Types of Concept Drift in News Recommendation Systems // International Journal of Computer Science & Information Technology (IJCSIT). — 2019. — Vol. 11. P. 87–105.
15. WhyLabs / whylogs: Open standard for logging ML data. — 2020–2025. — URL: <https://github.com/whylabs/whylogs> (дата обращения: 28.11.2025).
16. Xin D., Miao H., Parameswaran A., Polyzotis N. Production Machine Learning Pipelines: Empirical Analysis and Optimization Opportunities // arXiv preprint arXiv:2103.16007. — 2021. — URL: <https://arxiv.org/abs/2103.16007> (дата обращения: 28.11.2025).

ПРИЛОЖЕНИЕ В Аналитический обзор

1. Введение в проблему

1.1. Описание практической задачи

Практическая задача данного исследования заключается в экспериментальной проверке подходов к мониторингу состояния ML-моделей, эксплуатируемых в production-среде. В рамках задачи требуется выявлять как изменения во входных данных (data drift), так и деградацию качества предсказаний модели, используя комбинацию статистического анализа распределений признаков и обратной связи от внешних систем в виде агрегированных метрик качества и бизнес-показателей. Для решения задачи предполагается провести сравнительный анализ существующих методов обнаружения дрейфа и деградации качества, реализованных с использованием открытых инструментов мониторинга (таких как Evidently AI), и оценить их применимость в реальных сценариях. Экспериментальная часть включает моделирование дрейфа на синтетических наборах данных и использование Evidently AI для их выявления. Анализ выполняется с точки зрения чувствительности методов, частоты ложных срабатываний, вычислительной стоимости и требований к разметке данных.

1.2. Анализ существующих решений

Несмотря на активное развитие методов обнаружения дрейфа, существующие решения обладают рядом принципиальных ограничений.

Во-первых, статистические методы мониторинга признаков чувствительны к изменениям распределений входных данных, однако не всегда коррелируют с фактическим падением качества модели. Изменение распределения признаков может быть компенсировано устойчивостью модели, что приводит к ложным срабатываниям и избыточным перезапускам обучения [1]. В production-системах с высокой частотой обновлений это существенно увеличивает вычислительные затраты. Так, согласно результатам исследований, проведённых в Google, до 60%

автоматических переобучений моделей машинного обучения в production-пайплайнах не приводят к деплою обновлённых моделей и, как следствие, являются избыточными с точки зрения практического использования и вычислительных затрат [14].

Во-вторых, подходы, основанные на ошибках модели и истинных метках (например, ADWIN и другие performance-based детекторы), требуют своевременного доступа к размеченным данным. На практике, в задачах рекомендаций или обработки обращений пользователей, метки часто либо недоступны в реальном времени, либо формируются через косвенную бизнес-логику, что снижает применимость таких методов [12].

В-третьих, многие существующие решения рассматривают мониторинг дрейфа и мониторинг качества как разрозненные задачи. Системы либо фокусируются на анализе данных, либо на анализе метрик модели, не предлагая унифицированного механизма принятия решений. Это усложняет интеграцию в MLOps-pipeline и требует ручной настройки порогов и логики реакции на события [7].

Наконец, ряд методов демонстрирует высокую чувствительность, но страдает от повышенной частоты ложных тревог, либо обладает значительной вычислительной стоимостью, что делает их плохо масштабируемыми для потоков промышленного объёма.

1.3. Цель анализа

Целью данного аналитического обзора является систематический анализ и сравнительная оценка методов выявления дрейфа данных и механизмов обнаружения деградации качества ML-моделей в production-средах по следующим критериям: чувствительность к различным типам дрейфа, частота ложных срабатываний, вычислительная стоимость, задержка обнаружения, требования к разметке и интегрируемость в MLOps-систему.

На основе полученных результатов предполагается спроектировать унифицированный механизм мониторинга, объединяющий анализ дрейфа признаков и обратную связь по качеству предсказаний. Такой подход позволит снизить число непредвиденных падений точности моделей, повысить надёжность ML-систем и сократить операционные издержки, связанные с ручным контролем и несвоевременным переобучением.

2. Сравнительный анализ методов

2.1. Виды дрейфа данных

Дрейф признаков (covariate shift, data drift) представляет собой изменение распределений входных переменных при сохранении неизменной зависимости между признаками и целевой переменной [12]. В промышленных ML-системах такой тип дрейфа возникает особенно часто и связан с естественной эволюцией данных: сезонными колебаниями, изменением пользовательской аудитории, обновлением интерфейсов цифровых продуктов, корректировкой бизнес-процессов или сбоями в пайплайнах данных. Как отмечается в работе Chidiebere Joshua, data drift является наиболее распространённой формой деградации входных данных и в первую очередь обнаруживается через статистические аномалии в распределениях признаков, таких как смещение среднего, дисперсии или формы распределения [7]. При этом ключевая сложность заключается в том, что сам факт изменения распределений не обязательно приводит к ухудшению качества модели: современные алгоритмы, обладающие высокой устойчивостью и обобщающей способностью (например, ансамблевые методы), способны сохранять стабильные метрики даже при заметных сдвигах входных данных. В результате использование статистических тестов без учёта поведения модели может приводить к большому числу ложных срабатываний и избыточных переобучений.

Более критичным с точки зрения надёжности ML-систем является **дрейф концепта (concept drift)**, при котором изменяется сама функциональная

зависимость между входными признаками и целевой переменной. В этом случае модель продолжает получать данные, которые могут выглядеть «корректными» с точки зрения распределений, однако её предсказания постепенно теряют актуальность. В литературе подчёркивается, что именно **concept drift** является основной причиной «тихой деградации» моделей в **production**, когда система формально работает без ошибок, но фактически генерирует всё менее полезные или ошибочные решения. **Concept drift** может проявляться в различных формах: резкой (**sudden drift**), например при изменении регуляторных требований или запуске нового тарифного плана; постепенной (**gradual drift**), связанной с эволюцией пользовательских предпочтений; инкрементальной, когда изменения накапливаются незаметно; а также циклической или повторяющейся, характерной для сезонных бизнес-сценариев. Основная сложность его обнаружения заключается в том, что стандартные методы анализа **data drift** зачастую оказываются нечувствительными к таким изменениям, поскольку распределения признаков могут оставаться статистически стабильными, в то время как распределение ошибок и качество предсказаний ухудшаются [2, 5, 7].

Отдельно в исследованиях выделяется **виртуальный concept drift (virtual drift)**, при котором изменяется распределение входных данных или пространство признаков, но целевая зависимость остаётся прежней. Такой сценарий может возникать при изменении схемы **feature engineering**, обновлении источников данных или внедрении новых процедур нормализации и кодирования признаков. Несмотря на отсутствие реального изменения целевой функции, виртуальный дрейф может оказывать существенное влияние на стабильность обучения, интерпретацию мониторинговых метрик и работу автоматизированных **MLOps**-пайплайнов. В частности, статья подчёркивает, что в системах с автоматическим переобучением такие изменения нередко интерпретируются как сигнал деградации, что приводит к запуску ненужных циклов обучения и росту вычислительных затрат [2].

Таким образом, различные типы дрейфа данных отличаются не только источниками возникновения, но и характером влияния на модель, а также сложностью обнаружения. Data drift относительно хорошо выявляется статистическими методами, но слабо коррелирует с деградацией качества; concept drift, напротив, напрямую влияет на предсказания, но плохо обнаруживается на уровне распределений признаков. Это обосновывает необходимость комплексного подхода к мониторингу ML-систем промышленного уровня, сочетающего анализ распределений входных данных, мониторинг поведения модели и адаптивные методы обнаружения изменений во временной динамике ошибок и метрик качества.

2.2. Моделирование дрейфа на синтетических данных

В рамках экспериментального исследования была проведена серия экспериментов с целью анализа применимости статистических методов обнаружения дрейфа данных и оценки влияния дрейфа на качество моделей машинного обучения. Для этого использовались синтетические табличные наборы данных, сформированные на основе исходной выборки путём управляемого внесения смещений в распределения признаков. Генерация синтетического дрейфа осуществлялась с контролем типа и интенсивности изменений, включая сдвиг среднего, изменение дисперсии, замену распределения и комбинированные сценарии дрейфа для отдельных признаков.

Для выявления дрейфа данных в ходе экспериментов применялась библиотека **Evidently AI** [3]. Использовались следующие статистические критерии выявления дрейфа распределений числовых признаков: критерий Колмогорова–Смирнова (KS-test), Population Stability Index (PSI), Wasserstein distance и Jensen–Shannon divergence. Во всех рассмотренных сценариях синтетического смещения данные методы успешно выявляли изменения в распределениях признаков, демонстрируя высокую чувствительность к различным типам внесённого дрейфа.

В то же время экспериментальная оценка влияния дрейфа на качество моделей классификации показала, что наличие статистически значимого дрейфа признаков не всегда приводит к значительному ухудшению качества предсказаний. Модели логистической регрессии в ряде случаев демонстрировали снижение значений accuracy и F1-score на смещённых данных, тогда как более сложные и устойчивые алгоритмы, такие как случайный лес, сохраняли стабильное качество даже при зафиксированном статистическими тестами дрейфе входных распределений (см. таблицу 1 и рис. 1). Это свидетельствует о способности моделей с высокой нелинейной выразительностью адаптироваться к изменениям распределений признаков без немедленной деградации качества.

Таблица 1- сравнение метрик на исходных и смещенных данных

Модель	accuracy (исходные данные)	F1-score (исходные данные)	accuracy (смещенные данные)	F1-score (смещенные данные)
Логистическая регрессия	0.9	0.9	0.795	0.796
Случайный лес	0.956	0.956	0.933	0.933




Рис. 1 – график падения f1-score моделей и результатов статистического теста при увеличении интенсивности смещения признаков

Полученные результаты указывают на риск возникновения ложных срабатываний при использовании исключительно статистических тестов распределений признаков в качестве триггера для повторного обучения моделей. Таким образом, выявление data drift не может рассматриваться как достаточное условие для принятия решений о переобучении, что обосновывает необходимость комбинированного подхода к мониторингу ML-систем, включающего как анализ изменений входных данных, так и контроль фактического качества предсказаний моделей в production-среде.

2.3. Подходы к мониторингу деградации качества моделей

Мониторинг качества моделей машинного обучения в production-среде является ключевым элементом MLOps, поскольку изменения в зависимостях между входными признаками и целевой переменной (concept drift) могут происходить без заметных сдвигов в распределениях входных данных и, как следствие, не выявляться стандартными статистическими тестами. В подобных

сценариях модель формально продолжает получать данные, близкие к обучающим, однако её предсказания постепенно теряют актуальность. В прикладных ML-системах мониторинг качества используется не только как диагностический инструмент, но и как механизм инициации автоматизированного переобучения моделей, что делает выбор методов обнаружения concept drift критически важным для обеспечения устойчивости и надёжности всей системы [1].

Наиболее простым подходом является инициация переобучения на основе падения метрик качества, таких как accuracy, F1-score или бизнес-метрики (например, конверсии). Данный метод предполагает сравнение текущих значений метрик с эталонными и запуск переобучения при превышении заранее заданного порога снижения качества. Несмотря на простоту реализации, такой подход обладает рядом ограничений: он чувствителен к шуму и выбросам в данных, сезонным изменениям, требует ручного подбора порогов и, как правило, реагирует на проблему уже после того, как качество модели существенно ухудшилось. Кроме того, фиксированные пороги плохо масштабируются между различными моделями и сценариями эксплуатации.

Альтернативный подход основан на применении алгоритмов обнаружения точек изменения, анализирующих временную динамику ошибок или агрегированных метрик качества. Одним из наиболее известных методов данного класса является алгоритм **Adaptive Windowing (ADWIN)**, который автоматически поддерживает скользящее окно переменного размера и выявляет статистически значимые изменения в распределении наблюдаемых величин. Алгоритм последовательно проверяет гипотезу о неизменности среднего значения наблюдаемой величины, разделяя окно на историческую и текущую части и оценивая статистическую значимость различий между ними. При обнаружении устойчивого изменения ADWIN фиксирует момент дрейфа и отбрасывает устаревшие наблюдения, тем самым адаптируя механизм мониторинга к новым условиям эксплуатации модели. В контексте production-систем это позволяет

выявлять как резкие, так и постепенные формы concept drift без необходимости ручного задания порогов и размеров окон. Важным преимуществом ADWIN по сравнению с пороговыми методами является его способность отличать устойчивые изменения в режиме работы модели от случайных флуктуаций метрик. Это особенно актуально для production-систем с непостоянной нагрузкой и задержанной обратной связью, где кратковременные просадки качества не должны автоматически приводить к переобучению [2].

В литературе ADWIN рассматривается не только как самостоятельный метод обнаружения дрейфа, но и как компонент более сложных адаптивных моделей, в частности в связке с алгоритмом **Streaming Random Patches (SRP)** [2]. SRP представляет собой ансамблевый метод для потокового обучения, сочетающий идеи случайных подпространств и бутстреп-выборок, что обеспечивает высокую устойчивость к шуму и локальным изменениям данных. В рамках SRP каждый базовый классификатор обучается на собственной подвыборке признаков и объектов, а ADWIN используется для мониторинга его ошибки и принятия решения о замене деградировавших компонентов ансамбля.

Сравнительный анализ ADWIN и SRP показывает, что данные подходы решают принципиально разные, но взаимодополняющие задачи. ADWIN является универсальным механизмом обнаружения concept drift и может применяться поверх любых моделей в качестве триггера для переобучения или алертинга, однако сам по себе не обновляет модель. В то же время SRP представляет собой адаптивную модель, способную инкрементально подстраиваться под изменения данных за счёт замены отдельных базовых классификаторов, при этом ADWIN выступает в роли внутреннего детектора деградации. Таким образом, ADWIN ориентирован на обнаружение изменений, тогда как SRP — на адаптацию модели к этим изменениям.

В контексте рассматриваемого проекта, ориентированного на построение унифицированного механизма мониторинга и управления жизненным циклом

моделей в MLOps-системе, ADWIN представляется более универсальным и интегрируемым решением. Его использование позволяет разделить задачу обнаружения concept drift от конкретной архитектуры модели и применять единый механизм мониторинга для различных алгоритмов, включая как линейные модели, так и сложные ансамбли и нейросетевые методы.

2.4. Сравнение методов обнаружения дрейфа данных

В таблице 2 приведен сравнительный анализ рассмотренных методов по следующим выделенным критериям: чувствительность к различным типам дрейфа, частота ложных срабатываний, вычислительная стоимость, задержка обнаружения, требования к разметке и интегрируемость в MLOps-систему.

Таблица 2- сравнение методов выявления дрейфа данных

Метод	Чувствительность к различным видам дрейфа	Частота ложных срабатываний	Вычислительная стоимость	Требования к разметке	Интегрируемость в MLOps
Статистические тесты распределений признаков	Высокая для data drift; низкая для concept drift	Очень высокая	Низкая	Нет	Высокая
Пороговое отслеживание падения метрик качества	Высокая при выраженной деградации	Высокая при шумных метриках	Низкая	Требуется разметка или обратная связь	Средняя

ADWIN	Высокая для всех видов	Низкая	Низкая	Требуется разметка или агрегированная обратная связь	Средняя
SRP	Высокая	Низкая	Высокая	Требуется	Влияет на архитектуру моделей, трудозатратно
ML- подходы к выявлению дрейфа признаков	Высокая	Средняя	Высокая	Нет	Требует существенных трудозатрат

К методам, основанным на машинном обучении, относятся подходы, в которых дрейф выявляется путём обучения вспомогательных моделей, способных различать эталонные и текущие данные (например, classifier-based drift detection), либо за счёт анализа ошибки реконструкции (autoencoder-based методы). Такие подходы обладают повышенной чувствительностью к сложным и нелинейным изменениям в высокоразмерных данных, однако характеризуются более высокой вычислительной стоимостью, сложностью интерпретации результатов и интеграции в MLOps пайплайны.

3. Актуальность

Современные модели машинного обучения всё чаще развёртываются в production-средах и становятся неотъемлемой частью критически важных бизнес-процессов, включая рекомендательные системы телеком-операторов, автоматизированные классификаторы обращений в службы технической поддержки, системы обнаружения мошенничества и персонализации цифрового контента. В отличие от офлайн-сценариев, где данные считаются относительно

стационарными, production-ML-системы функционируют в условиях непрерывных потоков данных, изменяющегося пользовательского поведения и эволюционирующих бизнес-процессов. Эмпирические исследования production-пайплайнов в крупных технологических компаниях показывают, что данные, используемые для последовательных переобучений моделей, демонстрируют существенные изменения распределений, а сами модели могут обновляться десятки раз в сутки, что значительно усложняет обеспечение их стабильности и воспроизводимости [14].

Ключевой проблемой, возникающей в таких условиях, является дрейф данных и концепта (data drift и concept drift), при котором со временем изменяются статистические свойства входных признаков либо нарушается ранее выученная зависимость между признаками и целевой переменной. Многочисленные исследования подтверждают, что даже умеренные формы реального или виртуального дрейфа способны приводить к заметному снижению качества классификаторов и рекомендательных моделей, особенно в потоковых и онлайн-сценариях, где модель не имеет возможности периодически переобучаться в ручном режиме [2]. При этом деградация качества часто носит латентный характер: модель продолжает функционировать корректно с точки зрения инфраструктуры, однако её предсказания постепенно теряют релевантность, что отражается на бизнес-метриках, таких как точность рекомендаций, конверсия или удовлетворённость пользователей [7].

Дополнительную сложность представляет тот факт, что традиционные методы мониторинга, основанные исключительно на статистическом анализе входных данных, не всегда позволяют выявлять критические формы concept drift. В результате ML-системы могут демонстрировать статистически стабильные входные распределения при одновременном ухудшении качества предсказаний. В условиях MLOps это приводит к снижению доверия к автоматизированным решениям, росту числа инцидентов в production и увеличению операционных

затрат, связанных с поздним обнаружением проблем и экстренным переобучением моделей.

Кроме того, наивные стратегии автоматического переобучения, основанные на частом запуске retraining при любом обнаруженном изменении данных, могут приводить к противоположному эффекту — росту вычислительных затрат и нестабильности моделей. Исследования production-практик показывают, что значительная доля переобучений оказывается избыточной и не приводит к фактическому улучшению моделей, что дополнительно подчёркивает необходимость более интеллектуальных механизмов принятия решений о переобучении [14]. В этой связи актуальной научно-практической задачей становится разработка и анализ подходов к мониторингу, способных надёжно выявлять именно те изменения в данных и поведении моделей, которые действительно требуют вмешательства.

Таким образом, задача раннего и надёжного выявления дрейфа данных и деградации качества ML-моделей является одной из ключевых для обеспечения устойчивости production-ML-систем. Актуальность данной проблемы определяется как высокой динамичностью реальных данных, так и растущей сложностью современных моделей и MLOps-инфраструктур, что требует комплексных и научно обоснованных решений на стыке анализа данных, мониторинга качества и автоматизации жизненного цикла моделей.

4. Выводы для практического применения

Проведённый аналитический обзор и экспериментальное исследование показали, что задача мониторинга устойчивости ML-моделей в production-средах не может быть эффективно решена с использованием одного универсального метода. Статистические тесты сравнения распределений признаков демонстрируют высокую чувствительность к изменениям входных данных и могут использоваться как инструмент раннего обнаружения covariate drift. Однако, как отмечается в ряде работ, наличие статистически значимого дрейфа

признаков не является достаточным условием для деградации качества модели, особенно при использовании устойчивых и нелинейных алгоритмов, способных сохранять стабильные метрики в условиях изменяющихся распределений входных данных [7, 12].

Экспериментальная оценка влияния дрейфа на качество моделей подтвердила, что деградация метрик качества не всегда напрямую коррелирует с обнаруживаемыми изменениями распределений входных данных. В частности, в сценариях *concept drift*, связанных с изменением зависимости между признаками и целевой переменной, статистические методы часто оказываются недостаточными, поскольку распределения признаков могут оставаться относительно стабильными. Аналогичные выводы приводятся в работе Benni et al., где подчёркивается, что именно изменение поведения модели, а не входных данных, является ключевым индикатором потери актуальности предсказаний в потоковых и *production*-сценариях [2].

С практической точки зрения наиболее перспективным является комбинированный подход к мониторингу, при котором статистический анализ данных используется для диагностики изменений входного потока, а методы обнаружения точек изменения, такие как ADWIN, применяются для контроля временной динамики метрик качества или ошибок модели. В отличие от пороговых механизмов, ADWIN обеспечивает статистически обоснованное обнаружение устойчивых изменений и позволяет отличать реальные проявления *concept drift* от кратковременных флуктуаций, что особенно важно в *production*-системах с сезонностью, неравномерной нагрузкой и задержанной обратной связью [2].

Дополнительно результаты работы согласуются с промышленными наблюдениями, согласно которым наивные стратегии автоматического переобучения могут приводить к значительному числу избыточных *retraining*-

циклов [14]. Это подчёркивает важность использования более точных и интерпретируемых критериев для инициации переобучения.

Таким образом, результаты аналитического обзора и экспериментов подтверждают целесообразность перехода от изолированного мониторинга data drift или простого контроля падения метрик качества к интегрированным MLOps-подходам, сочетающим анализ распределений данных, мониторинг поведения моделей и адаптивные алгоритмы обнаружения изменений. Реализация такого подхода позволяет повысить устойчивость ML-систем, снизить количество ложных срабатываний и обеспечить более эффективное управление жизненным циклом моделей в условиях нестационарных данных.

СПИСОК ИСТОЧНИКОВ

1. Abhay, Dr., K K Vamsheesh, Mattihalli P., Namith G., Kumar R. S. Automated Drift Detection and Retraining Pipeline for ML Models // International Journal of Scientific Research in Engineering and Management (IJSREM). — 2025. — URL: <https://ijsrem.com/download/automated-drift-detection-and-retraining-pipeline-for-ml-models> (дата обращения: 22.11.2025).
2. Benni, Rashmi & Totad, Shashikumar & Mulimani, Deepa & K G, Karibasappa. Impact analysis of real and virtual concept drifts on the predictive performance of classifiers // Procedia Computer Science. — 2024. — Vol. 235. P. 617–627.
3. Evidently AI. — URL: <https://github.com/evidentlyai/evidently> (дата обращения: 23.11.2025).
4. Feldhans R., Wilke A., Heindorf S., Shaker M. H., Hammer B., Ngonga Ngomo A.-C., Hüllermeier E. Drift Detection in Text Data with Document Embeddings // Intelligent Data Engineering and Automated Learning, — 2021. — URL: https://www.researchgate.net/publication/356476524_Drift_Detection_in_Text_Data_with_Document_Embeddings (дата обращения: 28.11.2025).
5. Gama J., Medas P., Castillo G., Rodrigues P. Learning with drift detection // Brazilian Symposium on Artificial Intelligence. — 2004. — P. 286–295.
6. Garcia C. M., Koerich A. L., Britto Jr. A. de S., Barddal J. P. Methods for Generating Drift in Text Streams // arXiv preprint arXiv:2403.12328. — 2024. — URL: <https://arxiv.org/abs/2403.12328> (дата обращения: 28.11.2025).
7. Joshua Chidiebere. Automating Model Drift Detection in Production ML Pipelines Using Anomaly Detection Techniques // IEEE Transactions on Microwave Theory and Techniques, — 2025. — URL: https://www.researchgate.net/publication/392592315_Automating_Model_Drift_Det

[ection in Production ML Pipelines Using Anomaly Detection Techniques](#) (дата обращения: 23.11.2025).

8. Lu J., Liu A., Dong F., Gu F., Gama J., Zhang G. Learning under Concept Drift: A Review // IEEE Transactions on Knowledge and Data Engineering. — 2020. — Vol. 31, No. 12. P. 2346–2363.

9. River: machine learning for streaming data in Python // GitHub, — 2021-2025. — URL: <https://github.com/online-ml/river> (дата обращения: 27.11.2025).

10. Müller R., Abdelaal M., Stjelja D. Open-Source Drift Detection Tools in Action: Insights from Two Use Cases // arXiv preprint arXiv:2404.18673. — 2024. — URL: <https://arxiv.org/abs/2404.18673> (дата обращения: 23.11.2025).

11. NannyML: Open-source Python library for model monitoring in production. — 2020–2025. — URL: <https://github.com/NannyML/nannyml> (дата обращения: 23.11.2025).

12. Nayer W., Farouk A., Said D., Khodeir N., Fayek M. Detection and Handling of Different Types of Concept Drift in News Recommendation Systems // International Journal of Computer Science & Information Technology (IJCSIT). — 2019. — Vol. 11. P. 87–105.

13. WhyLabs / whylogs: Open standard for logging ML data. — 2020–2025. — URL: <https://github.com/whylabs/whylogs> (дата обращения: 28.11.2025).

14. Xin D., Miao H., Parameswaran A., Polyzotis N. Production Machine Learning Pipelines: Empirical Analysis and Optimization Opportunities // arXiv preprint arXiv:2103.16007. — 2021. — URL: <https://arxiv.org/abs/2103.16007> (дата обращения: 28.11.2025).